

Bank Customer Churn

Zakia YAHIA CHERIF

Projet data analysis - Bloc 6 RNCP CDSD

Jedha

PLAN

- Contexte
- EDA
- Modélisation
- Recommandations et Conclusion



Contexte : Ce dataset contient des informations sur des clients de banque, et l'objectif principal est de prédire si un client va quitter la banque ou rester, en se basant sur diverses caractéristiques démographiques, financières et comportementales.

Problématique : Comment prédire le départ des clients en banque et quels sont les facteurs qui influencent leur départ ?

Jedha

PRESENTATION DU DATASET

RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited	Complain	Satisfaction Score	Card Type	Point Earned
1	15634602	Hargrave	619	France	Female	42	2	0.00	1	1	1	101348.88	1	1	2	DIAMOND	464
2	15647311	Hill	608	Spain	Female	41	1	83807.86	1	0	1	112542.58	0	1	3	DIAMOND	456
3	15619304	Onio	502	France	Female	42	8	159660.80	3	1	0	113931.57	1	1	3	DIAMOND	377
4	15701354	Boni	699	France	Female	39	1	0.00	2	0	0	93826.63	0	0	5	GOLD	350
5	15737888	Mitchell	850	Spain	Female	43	2	125510.82	1	1	1	79084.10	0	0	5	GOLD	425

- 10000 lignes et 18 Columns
- EXITED = 1 => PARTI , EXITED = 0 => PRÉSENT
- Pas de doublons
- Pas de valeurs manquantes

Jedha

EDA



1 – Suppression des colonnes inutiles

	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited	Complain	Satisfaction Score	Card Type	Point Earned
0	619	France	Female	42	2	0.00	1	1	1	101348.88	1	1	2	DIAMOND	464
1	608	Spain	Female	41	1	83807.86	1	0	1	112542.58	0	1	3	DIAMOND	456
2	502	France	Female	42	8	159660.80	3	1	0	113931.57	1	1	3	DIAMOND	377
3	699	France	Female	39	1	0.00	2	0	0	93826.63	0	0	5	GOLD	350
4	850	Spain	Female	43	2	125510.82	1	1	1	79084.10	0	0	5	GOLD	425

- RowNumber
- CustomerId
- Surname
- Complain

2 – Calcul des principales valeurs statistiques

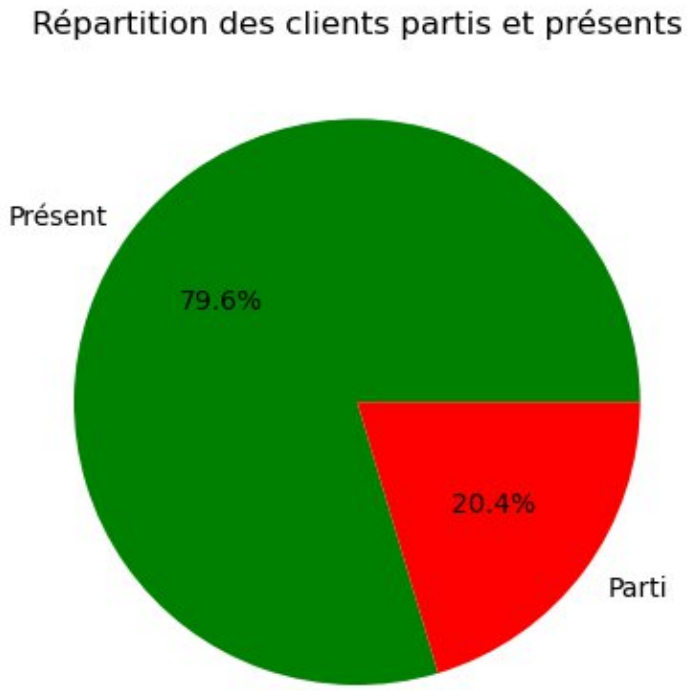
	CreditScore	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited	Complain	Satisfaction Score	Point Earned
count	10000.000000	10000.000000	10000.000000	10000.000000	10000.000000	10000.00000	10000.000000	10000.000000	10000.000000	10000.000000	10000.000000	10000.000000
mean	650.528800	38.921800	5.012800	76485.889288	1.530200	0.70550	0.515100	100090.239881	0.203800	0.204400	3.013800	606.515100
std	96.653299	10.487806	2.892174	62397.405202	0.581654	0.45584	0.499797	57510.492818	0.402842	0.403283	1.405919	225.924839
min	350.000000	18.000000	0.000000	0.000000	1.000000	0.00000	0.000000	11.580000	0.000000	0.000000	1.000000	119.000000
25%	584.000000	32.000000	3.000000	0.000000	1.000000	0.00000	0.000000	51002.110000	0.000000	0.000000	2.000000	410.000000
50%	652.000000	37.000000	5.000000	97198.540000	1.000000	1.00000	1.000000	100193.915000	0.000000	0.000000	3.000000	605.000000
75%	718.000000	44.000000	7.000000	127644.240000	2.000000	1.00000	1.000000	149388.247500	0.000000	0.000000	4.000000	801.000000
max	850.000000	92.000000	10.000000	250898.090000	4.000000	1.00000	1.000000	199992.480000	1.000000	1.000000	5.000000	1000.000000

Le problème est-il réel ?

Répartition des clients

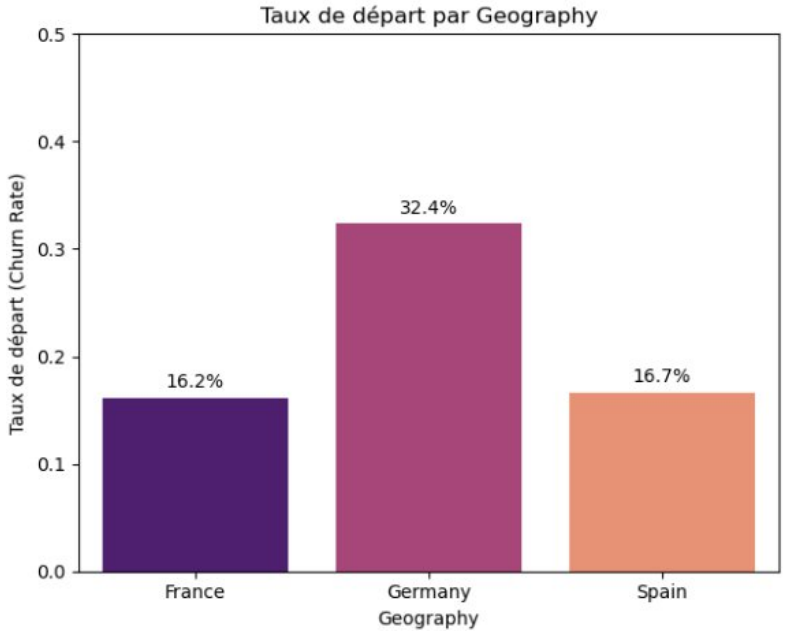
Statut client	Nombre de clients	Pourcentage
Présent	7962	79,62%
Parti	2038	20,38%

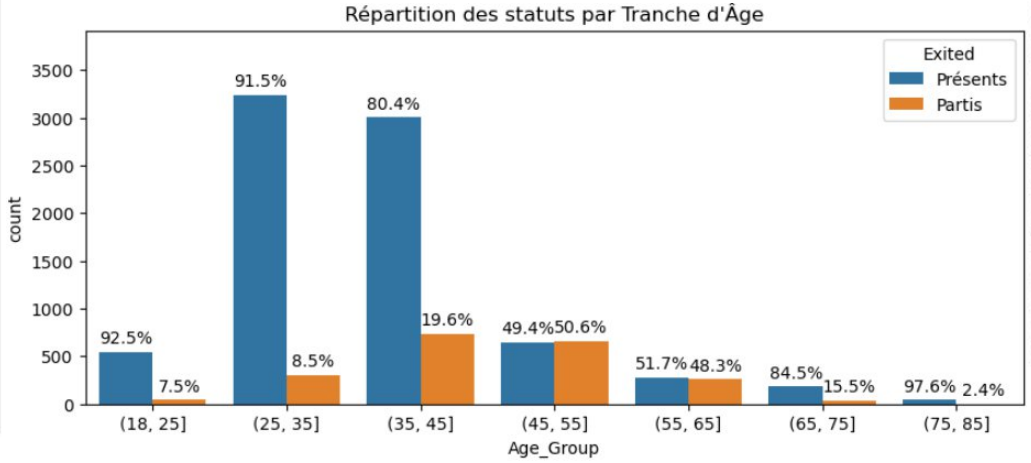
Total des clients : 10 000

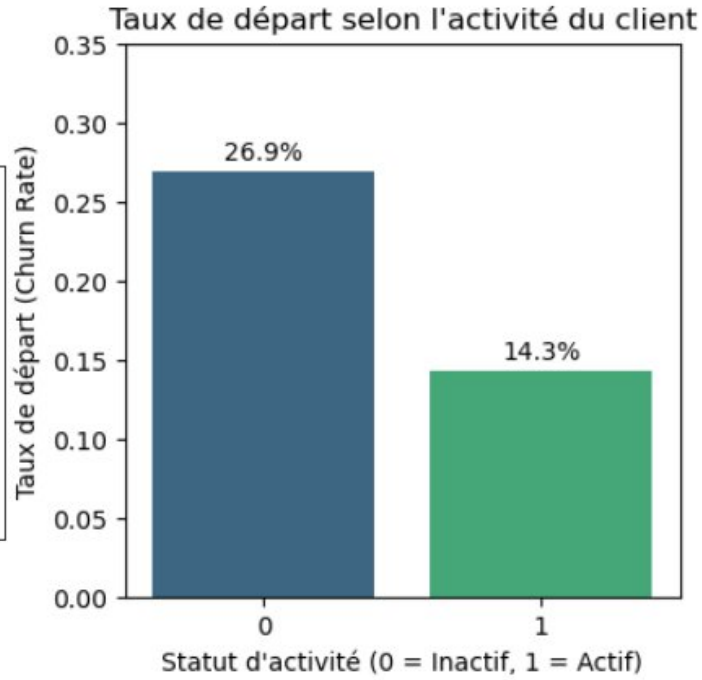


Le pourcentage de désabonnement représente une proportion suffisament importante pour justifier la recherche de facteurs explicatifs et eventuellement mettre en place un modele prédictif

VISUALISATION







Allemagne a le taux de churn le plus élevé

De 45 à 55 ans , les clients sont majoritairement partis

L’inactivité est un signal d’alerte majeur

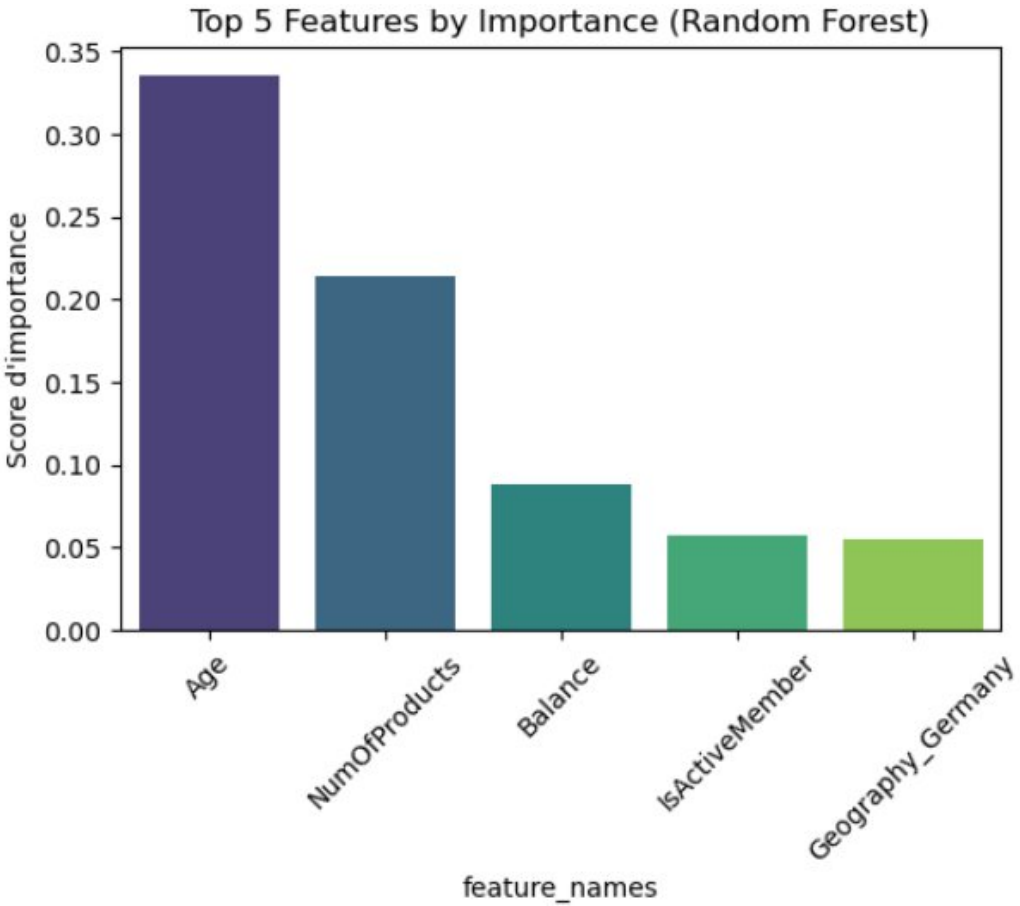
MODELISATION

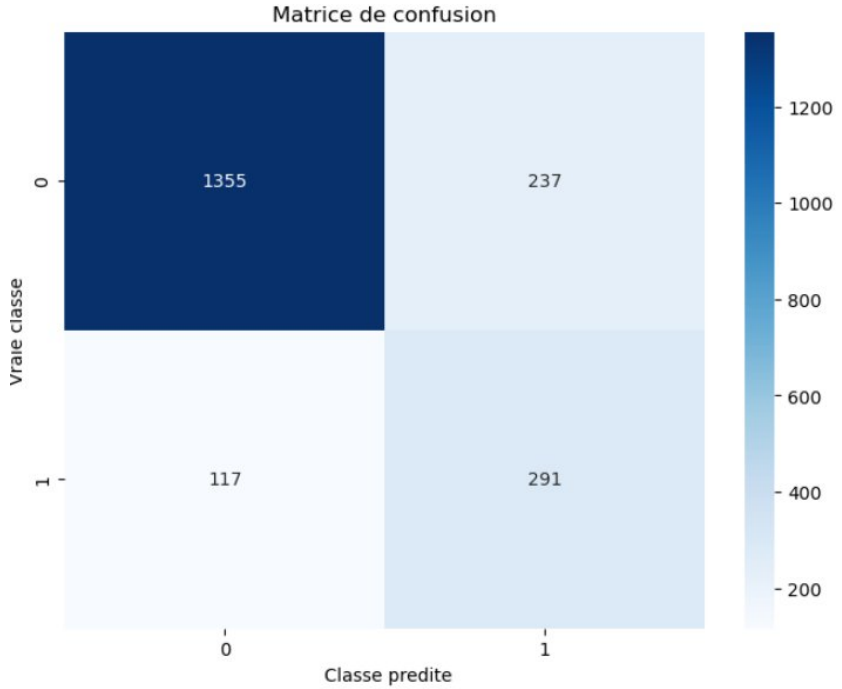
Métrique	Regression Logistique	Random Forest	Gagnant
Accuracy Test	71.15%	82.3%	Random Forest
Rappel (classe 1)	72.3%	71.3%	Egalité très proche
Faux Négatifs	113	117	Egalité très proche
Faux positifs	464	237	Random Forest
Stabilité	Bonne	Excellente	Random Forest

Random Forest retenu : ACC 82,3 % et recall 71,3 % sur le jeu de test.

Le modèle capte environ 71 % des clients réellement partis tout en conservant une précision d'environ 55 %.

Il est plus stable et détecte mieux les clients à risque que la Régression Logistique, tout en réduisant les fausses alertes (Faux Positifs).





Les variables les plus contributives sont l'âge, le nombre de produits, le solde, client actif, Allemagne.

Le modèle doit être utilisé comme outil d'aide à la décision, pas comme décision automatique.

VISUALISATION VARIABLES PREDICTIFS

RECOMMANDATIONS

L'analyse des variables nous donne 3 recommandations claires :

1

Cibler les 45-55 ans et les clients inactifs

Pourquoi Ce sont les profils qui présentent le taux de départ le plus élevé.

Comment Campagnes de réengagement personnalisées pour les membres inactifs et offres de fidélisation pour les quadragénaires.

2

Auditer la vente de 3 produits ou plus

Pourquoi Le nombre de produits est le 2e facteur de départ : les clients à 3-4 produits partent presque systématiquement.

Comment Stopper la vente forcée du 3e produit. Auditer la qualité et le tarif de ces produits pour comprendre cette fuite.

3

Concentrer les efforts sur le marché allemand

Pourquoi L'Allemagne ressort comme un facteur de risque majeur, en particulier chez les femmes.

Comment Lancer une enquête de satisfaction locale et revoir l'offre bancaire proposée en Allemagne.

CONCLUSION

Ce que ce projet démontre :

Les modèles testés montrent qu'il est possible d'anticiper le départ des clients d'une banque et d'agir avant qu'il ne se concrétise, à partir de données comportementales simples à collecter.

LIMITE DU PROJET

La variable Complain (plainte) a été exclue de la modélisation pour éviter une fuite de données. Or, dans la réalité, une plainte est souvent le tout premier signe d'un départ imminent.

PERSPECTIVE

Les moyens et ressources nécessaires pour analyser le contenu de ces plaintes ne sont pas disponibles à ce stade. Comprendre la cause racine de l'insatisfaction reste une piste ouverte pour de futures recherches.



Jedha

MERCI